


法律声明

- 本课件包括：演示文稿，示例，代码，题库，视频和声音等，小象学院拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意，我们将保留一切通过法律手段追究违反者的权利。



关注 **小象学院**



分类模型 (2)

--Robin

目录

- 逻辑回归
- 正则化
- 支持向量机


SVM

Feature vector Class value



$$f(x, w, b) = \text{sign}(w \circ x + b)$$

$$= \text{sign}(\sum w[i]x[i] + b)$$



目标：找到一个可以分割这两个类别的边界


SVM

- 例子，假设这个边界已知

Feature vector x → f → Class value \hat{y}

$$f(x, w, b) = \text{sign}(w \cdot x + b)$$

$$\begin{aligned}x_1 - x_2 &= 0 \\ w &= [1, -1], \\ b &= 0\end{aligned}$$



SVM

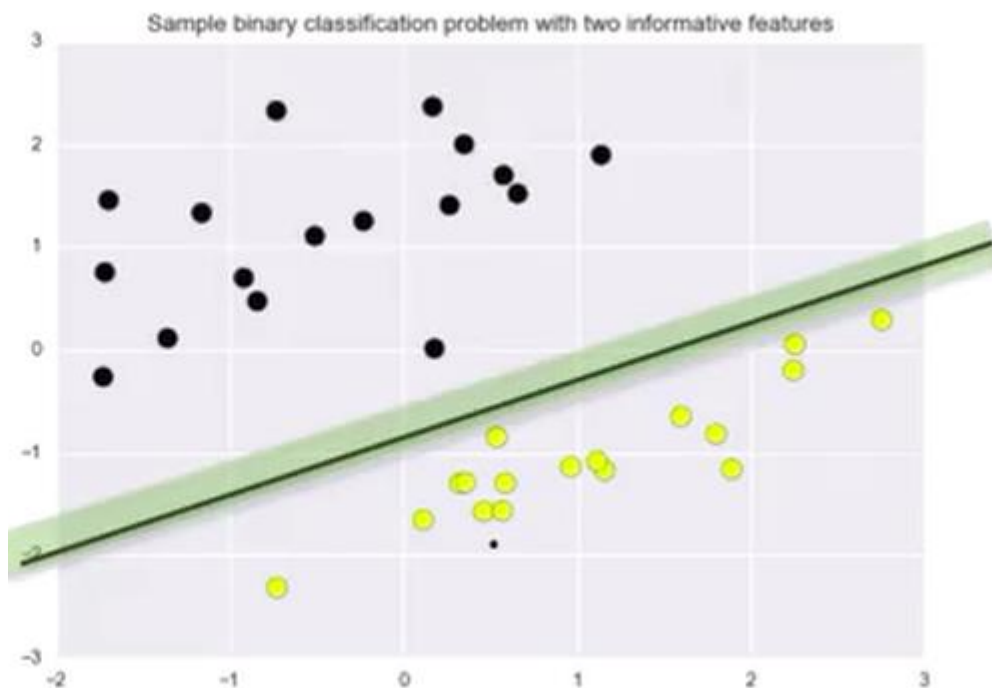
- 间隔（Margin）



$$f(x, w, b) = \text{sign}(w \cdot x + b)$$


分类器间隔：

- 分类边界可以扩展到样本点的最大宽度。
- 例子中分类器的间隔就是绿色区域



SVM

- 间隔 (Margin)



支持向量

- 带不等式约束的优化问题

$$\begin{aligned} \max_{w,b} \quad & \frac{2}{\|w\|} \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

SVM

- 拉格朗日乘子法

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \Rightarrow \quad L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))$$

s.t. $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m.$

KKT条件

其中 $\boldsymbol{\alpha} = (\alpha_1; \alpha_2; \dots; \alpha_m)$ ，令 L 对 w 和 b 的偏导为零可得：

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad 0 = \sum_{i=1}^m \alpha_i y_i$$

$$\begin{cases} \alpha_i \geq 0; \\ y_i f(\mathbf{x}_i) - 1 \geq 0; \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0 \end{cases}$$

将 w 带入 L 中，可得


$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \quad \text{s.t.} \quad \sum_{i=1}^m \alpha_i y_i = 0,$$
$$\alpha_i \geq 0, \quad i = 1, 2, \dots, m.$$

二次规划问题：可以使用SMO算法进行求解

SVM

核函数

- 如果数据线性不可分，怎么办？



- 将样本从原始空间映射到一个更高维的特征空间，从而使得样本在特征空间内线性可分

原始空间

$$f(x) = w^T x + b$$



$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j$$

特征空间

$$f(x) = w^T \phi(x) + b$$



$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \boxed{\phi(x_i)^T \phi(x_j)}$$

SVM

特征空间

$$f(x) = w^T \phi(x) + b$$



$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(x_i)^T \phi(x_j)$$



$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \kappa(x_i, x_j)$$



$$f(x) = w^T \phi(x) + b$$

$$= \sum_{i=1}^m \alpha_i y_i \phi(x_i)^T \phi(x) + b$$

$$= \sum_{i=1}^m \alpha_i y_i \kappa(x, x_i) + b$$

如果特征空间维数很高，直接计算会非常困难



核函数

$$\kappa(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle = \phi(x_i)^T \phi(x_j)$$

常用的核函数

名称	表达式	参数
线性核	$\kappa(x_i, x_j) = x_i^T x_j$	
多项式核	$\kappa(x_i, x_j) = (x_i^T x_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(x_i, x_j) = \exp\left(-\frac{\ x_i - x_j\ ^2}{2\sigma^2}\right)$	$\sigma > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(x_i, x_j) = \exp\left(-\frac{\ x_i - x_j\ }{\sigma}\right)$	$\sigma > 0$
Sigmoid 核	$\kappa(x_i, x_j) = \tanh(\beta x_i^T x_j + \theta)$	\tanh 为双曲正切函数, $\beta > 0, \theta < 0$


SVM

$$\min_f \sum_{i=1}^n V(f(x_i), y_i) + \lambda R(f)$$

损失函数

正则项

$$C=1/\lambda$$



- 正则项中的C值决定了正则化的强度
- C值越大，正则化越弱 -> narrow margin
- C值越小，正则化越强 -> large margin

`sklearn.svm.SVC`

联系我们

小象学院：互联网新技术在线教育领航者

— 微信公众号：**小象学院**

